

EXAMEN FINAL: BIG DATA



Réaliser par : LEHCENE MOHAMED LEMINE

TECHNOLOGIES ET OUTILS UTILISEES







Enoncé:

L'entreprise Tech-solution souhaite traiter ces données de son site e-commerce au moyen d'une application Spark d'une manière parallèle est distribuée. L'entreprise possède des données stockées dans une base de données relationnel. L'objectif est de traiter ces données en utilisant Spark SQL à travers les APIs DataFrame en utilisant PySpark (Python) pour extraire des informations utiles afin de prendre des décisions.

I. Traitement de données stockées dans Mysql

L'entreprise souhaite extraire des informations à partir des deux tables CLIENTS et COMMANDES (Voir les figures 1et 2), les deux tables sont créés dans une base de données MYSQL nommée DB_COMMERCE.



Figure 1 : structure de la table CLIENTS

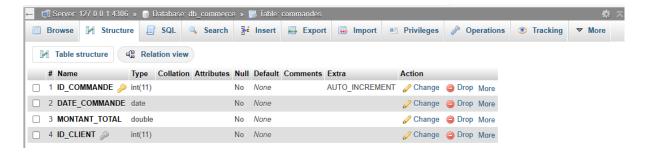


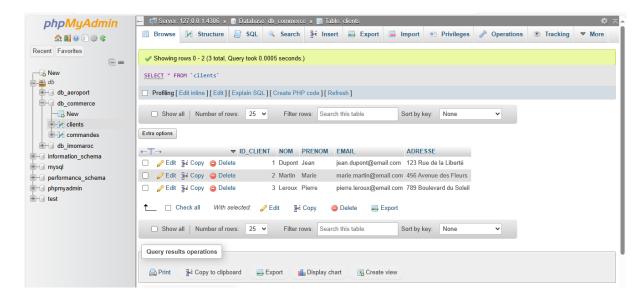
Figure 2 : structure de la table : COMMANDES

Contenu du Base de données

Requête SQL: pour ajouter des clients dans tables clients

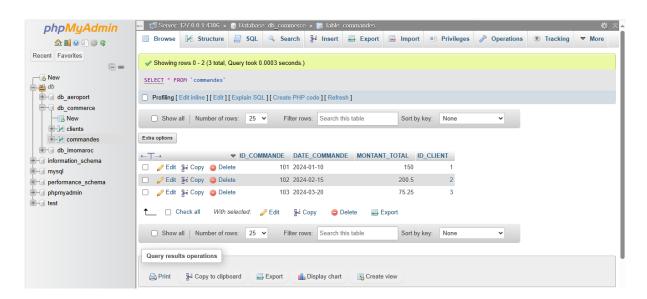
INSERT INTO clients (ID_CLIENT, NOM, PRENOM, EMAIL, ADRESSE)

VALUES (1, 'Dupont', 'Jean', 'jean.dupont@email.com', '123 Rue de la Liberté'), (2, 'Martin', 'Marie', 'marie.martin@email.com', '456 Avenue des Fleurs'), (3, 'Leroux', 'Pierre', 'pierre.leroux@email.com', '789 Boulevard du Soleil')



Requête SQL : pour quel quelle que infos dans table commandes

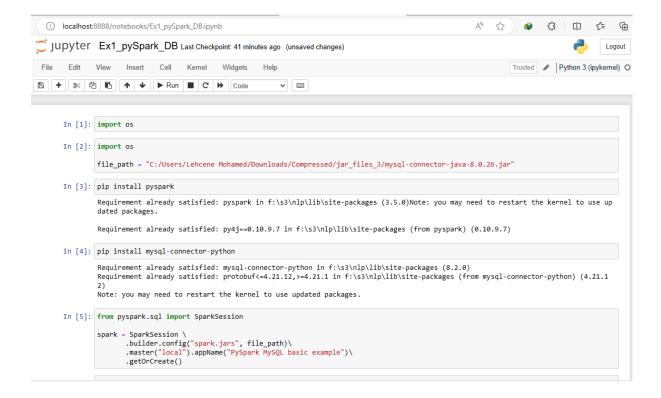
INSERT INTO commande (ID_COMMANDE, DATE_COMMANDE, MONTANT_TOTAL, ID_CLIENT) VALUES (101, '2024-01-10', 150.00, 1), (102, '2024-02-15', 200.50, 2), (103, '2024-03-20', 75.25, 3)

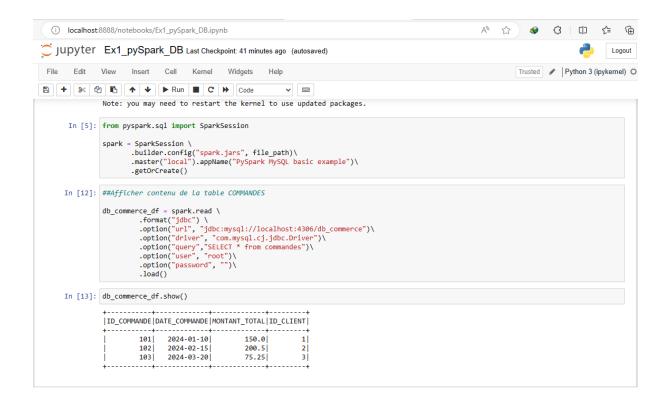


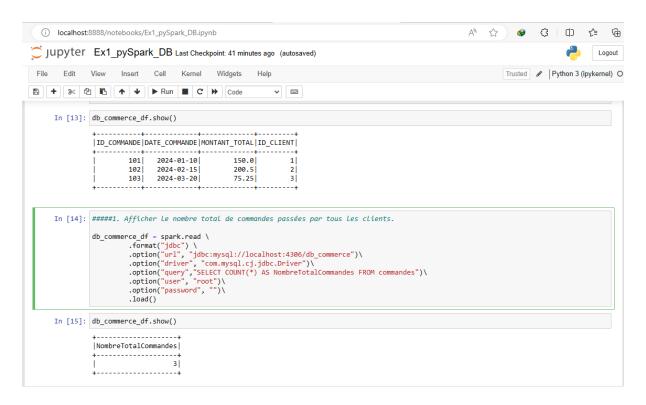
Travail à faire :

Vous créez la base de données et les tables et vous répondez aux questions suivantes en utilisant PySpark (Python):

1 - Afficher le nombre total de commandes passées par tous les clients.

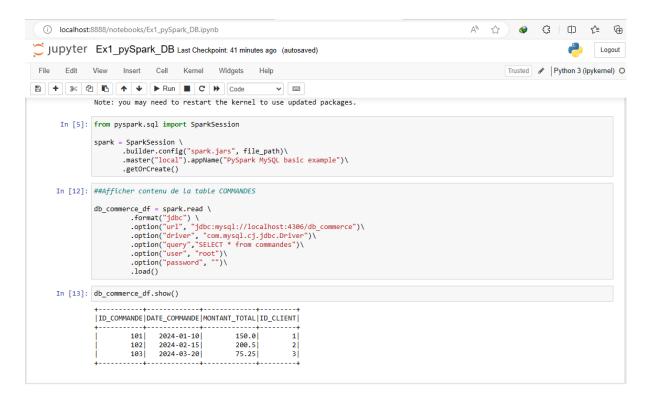






⇒ Voici résultat

2- Afficher le client qui a dépensé le plus (en terme de montant).

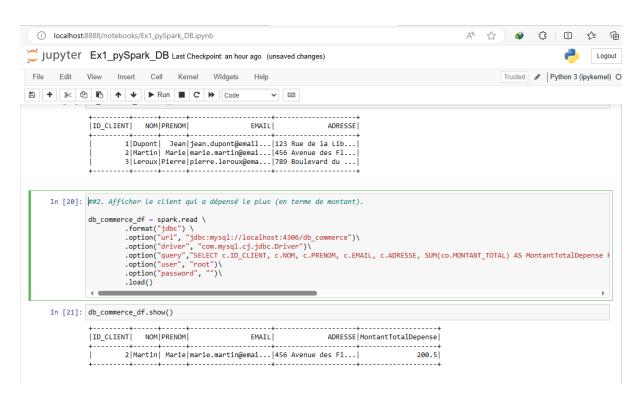


⇒ Pour afficher contenu du tableau commandes

⇒ Pour afficher contenu du tableau clients

Requête SQL:

SELECT c.ID_CLIENT, c.NOM, c.PRENOM, c.EMAIL, c.ADRESSE,
SUM(co.MONTANT_TOTAL) AS MontantTotalDepense FROM clients c JOIN
commandes co ON c.ID_CLIENT = co.ID_CLIENT GROUP BY c.ID_CLIENT,
c.NOM, c.PRENOM, c.EMAIL, c.ADRESSE ORDER BY MontantTotalDepense
DESC LIMIT 1



⇒ Voici le résultat

3- Afficher la moyenne des dépenses par client.

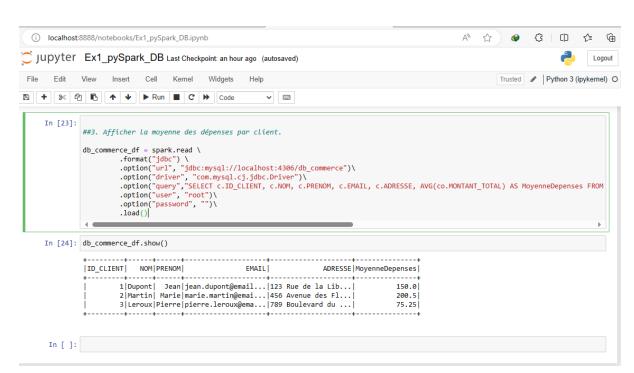
Requête SQL:

SELECT c.ID_CLIENT, c.NOM, c.PRENOM, c.EMAIL, c.ADRESSE,

AVG(co.MONTANT_TOTAL) AS MoyenneDepenses FROM clients c JOIN

commandes co ON c.ID_CLIENT = co.ID_CLIENT GROUP BY c.ID_CLIENT,

c.NOM, c.PRENOM, c.EMAIL, c.ADRESSE

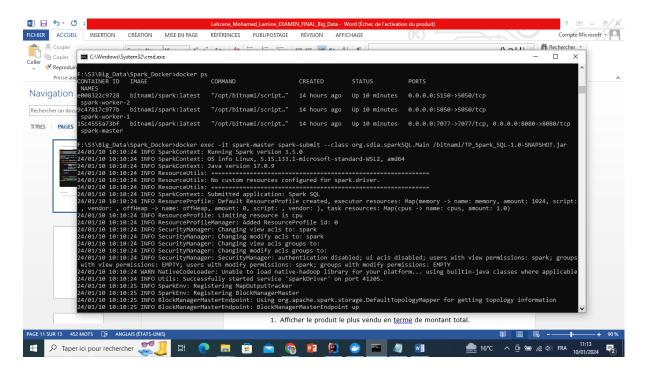


⇒ Voici le résultat

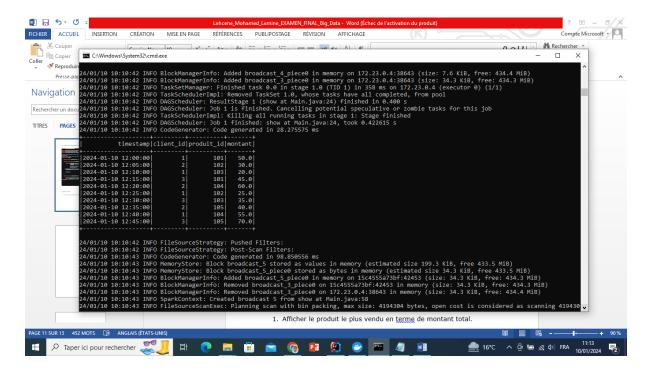
II. Traitement de données CSV.

```
package org.sdia.sparkSQL;
import org.apache.spark.sql.Dataset;
import org.apache.spark.sql.Row;
import org.apache.spark.sql.SparkSession;
// Press Shift twice to open the Search Everywhere dialog and type `show
whitespaces`,
public class Main {
   public static SparkSession spark;
   public static void main(String[] args) {
        spark = SparkSession.builder()
                .appName("Spark SQL")
                 .master("spark://spark-master:7077")
                .getOrCreate();
      // Charge les données des incidents à partir du ficher extension csv
        Dataset<Row> df = loadDataFromFileExCSV(spark);
        df.show();
   private static Dataset<Row> loadDataFromFileExCSV(SparkSession spark) {
       // return spark.read().option("header", true).csv("myFile.csv");
        return spark.read().format("csv").option("header",
```

⇒ Capture



⇒ Pour afficher liste de containers démarrés



⇒ Voici les contenus du fichier csv

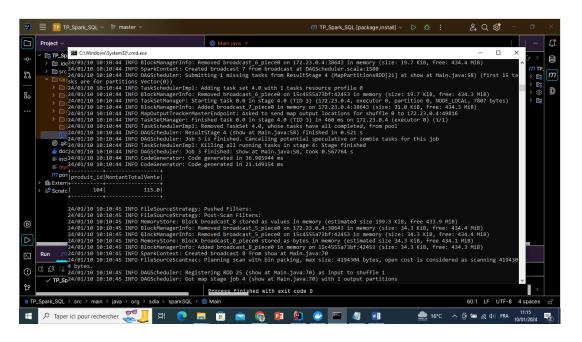
Travail à faire :

1. Afficher le produit le plus vendu en terme de montant total.

⇒ Code source

```
// Afficher le produit le plus vendu en termes de montant total
afficherProduitPlusVenduTermMontantToal(df);
```

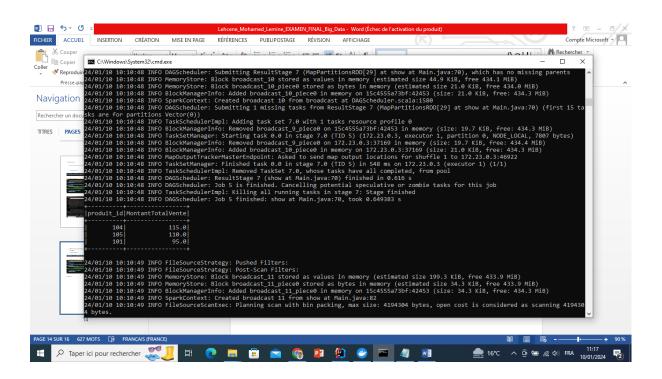
⇒ Capture d'écran du résultat



- 2. Afficher les 3 produits les plus vendus dans l'ensemble des données.
- ⇒ Code source

```
// Afficher les 3 produits les plus vendus en termes de montant total
afficher3PlusVendusTermsMontantTotal(df);
```

⇒ Capture d'écran du résultat



- 3- Afficher le montant total des achats pour chaque produit.
 - ⇒ Code source :

```
// Afficher le montant total des achats pour chaque produit
afficherMontantTotalAchtsChaqueProduit(df);
```

⇒ Capture d'écran de résultat :

